Perceptron + letters

Autor: Adam Polański

Klasa Perceptron

Wczytuje klase `Perceptron` z biblioteki sklearn.

```
from sklearn.linear_model import Perceptron
```

Klasa SLP

Tworzenie klasy SLP krok po kroku:

1. Na początku stworzyłem konstruktor klasy. Nie ma tu nic szczególnego.
2. Stworzyłem metode `fit(self, X, y)` , a w niej listę `self.perceptrons_ = [0] * len(X)` , która będzie przechowywała tyle obiektów klasy `Perceptron` , aby na każdą litere przypadał dokładnie jeden z nich.

   Tym razem, nie tworzę listy `self.errors` , ponieważ klasa `Perceptron` z biblioteki *sklearn* nie posiada swojej tablicy *errors_* ani żadnego jej odpowiednika.

   Następnie dla każdej litery tworze obiekt typu `Perceptron` i wywołuje metode `fit()` tego obiektu, przekazując w argumentach wszsytkie 10 liter oraz odpowiedni wektor oczekiwanej odpowiedzi.
3. Tworzę metode `predict(self, X)` , która ma za zadanie generować wektory odpowiedzi.

   Tworzę w niej 2-wymiarową tablice zer, każdy wiersz odpowiada za odpowiedzi jednego perceptrona, a każda kolumna za jedną literę przekazaną w postaci elementu listy X.

   Dla każdego perceptrona wywołuje jego metode `predict()` i jej wynik zapisuje do odpowiedniego wiersza. Na koniec zwracam uzyskany zestaw odpowiedzi.
4. Tworzę metode `misclassified(self, X, y)` , która korzystając z faktu, że odpowiedzi są zapisane w postaci liczb '*-1*' lub '*1*' zwraca sumę błędów ostatniego wywołania metody `predict(X)` (wynik wywołania metody zapisany jest w zmiennej `self.predictions`) w stosunku do zestawu odpowiedzi '*y*'.

   Aby uzyskać sumę błędów, najpierw 'odwracam' tablice `self.predictions` (dla każdego i w tablicy `self.predictions` wykonaj `i = i * (-1)`). Aby nie modyfikować orginalnej tablicy odpowiedzi, wynik takiego działania zapisuje do zmiennej lokalnej.

   Następnie sumuje każdy element z X i y, a wynik:

   - '0' : oznacza że w danej komórce nie ma błędu
   - '-2' : oznacza, że dany perceptron zareagował pozytywnie, mimo że nie powinien.
   - '2' : oznacza, że dany perceptron nie zareagował pozytywnie, mimo że powinien.

   Z każdego elementu takiej 'zsumowanej' tablicy, biore wartość bezwzględną (nie interesują nas typy błędów, a ich ilość) oraz wykonuje dzielenie całkowite przez 2, a następnie sumuje wszystkie elementy do jednej zmiennej.
5. Ostatnia funkcja, to funkcja `show(self, X)` , która ma za zadanie wyświetlić zbiór liter 'X' w postaci graficznej.

```
import numpy as np
import matplotlib.pyplot as plt
class SLP(object):
  def __init__(self, eta=0.05, n_iter=10, random_state=1):
    self.eta = eta
    self.n_iter = n_iter
    self.random_state = random_state

  def fit(self, X, y):
    self.perceptrons_ = [0] * len(X)
    for i in range(0, len(X)):
      self.perceptrons_[i] = Perceptron(eta0=self.eta, max_iter=self.n_iter, random_state=self.random_state)
      self.perceptrons_[i].fit(X, y[i])

  def predict(self, X):
    self.predictions = np.zeros((len(self.perceptrons_), len(self.perceptrons_)))
    for i in range(0, len(self.perceptrons_)):
      self.predictions[i, :] = self.perceptrons_[i].predict(X)
    return self.predictions

  def misclassified(self, X, y):
    result = 0
    predictions = self.predictions
    predictions = [list(map(lambda x: int(x * (-1)), i)) for i in predictions]
    for i in range(0, len(y)):
      result =  result + (sum(map(lambda x: abs(x) // 2, map(sum, zip(predictions[i], y[i])))))
    return result
```

```
  def show(self, X):
    fig, axs = plt.subplots(2, 5, figsize=(14, 8), sharex='col', sharey='row')

    for i, x in enumerate(X):
      ax = axs[i // 5, i % 5]
      ax.imshow(x.reshape(7, 5), cmap='binary')

    plt.show()
```

Przygotowywanie danych.

Wczytuje plik z danymi z dysku.

```
import pandas as pd
from google.colab import files
uploaded = files.upload()
```

Wybierz pliki letters.data

- **letters.data**(n/a) - 4361 bytes, last modified: 1.06.2023 - 100% done

```
Saving letters.data to letters.data
```

Tworzę obiekt perceptron. Następnie przekazuje dane z pliku do zmiennej df typu DataFrame i ucinam niepotrzebne wiersze (zostawiam tylko moje przypadki). Aby sprawdzić poprawność danych, wyświetlam 10 ostatnich wierszy.

```
net = SLP()

import io
df = pd.read_csv(io.BytesIO(uploaded['letters.data']), header = None)
#my_cases = '10 11 12 13 14 15 16 17 18 19'   # dane z przykładu
my_cases = '2 4 8 9 12 13 14 17 20 23'
my_cases = list(map(int, my_cases.split()))
print(my_cases)
df = df.iloc[my_cases]
df.head(10)
```

```
[2, 4, 8, 9, 12, 13, 14, 17, 20, 23]
```

	0	1	2	3	4	5	6	7	8	9	...	51	52	53	54	55	56	57	58	59	60
2	-1	1	1	1	-1	1	-1	-1	-1	1	...	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
4	1	1	1	1	1	1	-1	-1	-1	-1	...	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
8	-1	1	1	1	-1	-1	-1	1	-1	-1	...	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
9	1	1	1	1	1	-1	-1	-1	-1	1	...	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
12	1	-1	-1	-1	1	1	1	-1	1	1	...	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
13	1	-1	-1	-1	1	1	-1	-1	-1	1	...	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
14	-1	1	1	1	-1	1	-1	-1	-1	1	...	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1
17	1	1	1	1	-1	1	-1	-1	-1	1	...	-1	1	-1	-1	-1	-1	-1	-1	-1	-1
20	1	-1	-1	-1	1	1	-1	-1	-1	1	...	-1	-1	-1	-1	1	-1	-1	-1	-1	-1
23	1	-1	-1	-1	1	1	-1	-1	-1	1	...	-1	-1	-1	-1	-1	-1	-1	1	-1	-1

10 rows × 61 columns

Następnie rozdzielam każdy wiersz na dane litery przechowywane w 'X' oraz dane odpowiedzi przechowywane w 'y'. Dodatkowo, ucinam wszystkie niepotrzebne kolumny ze zmiennej 'y' (nie ma sensu trzymać np. kolumny o indeksie 3, jeżeli wiersz 3 i tak został ucięty). Na końcu wyświetlam zawartość obu zmiennych.

```
X = df.iloc[:, :35].values
y = df.iloc[:, 35:].values
y = y[:, my_cases]

print(X)
print('\n\n')
print(y)
```

```
[[-1  1  1  1 -1  1 -1 -1 -1  1  1 -1 -1 -1 -1  1 -1 -1 -1 -1  1 -1 -1 -1
  -1  1 -1 -1 -1  1 -1  1  1  1 -1]
 [ 1  1  1  1  1  1 -1 -1 -1 -1  1 -1 -1 -1 -1  1  1  1  1 -1  1 -1 -1 -1
  -1  1 -1 -1 -1 -1  1  1  1  1  1]
 [-1  1  1  1 -1 -1 -1  1 -1 -1 -1 -1  1 -1 -1 -1 -1  1 -1 -1 -1 -1  1 -1
  -1 -1 -1  1 -1 -1 -1  1  1  1 -1]
 [ 1  1  1  1  1 -1 -1 -1 -1  1 -1 -1 -1 -1  1 -1 -1 -1 -1  1 -1 -1 -1 -1
   1  1 -1 -1 -1  1 -1  1  1  1 -1]
 [ 1 -1 -1 -1  1  1  1 -1  1  1  1 -1  1 -1  1  1 -1 -1 -1  1  1 -1 -1 -1
   1  1 -1 -1 -1  1  1 -1 -1 -1  1]
 [ 1 -1 -1 -1  1  1 -1 -1 -1  1  1  1 -1 -1  1  1 -1  1 -1  1  1 -1 -1  1
```

```
  1  1 -1 -1 -1  1  1 -1 -1 -1  1]
 [-1  1  1  1 -1  1 -1 -1 -1 -1  1  1 -1 -1 -1 -1  1  1 -1 -1 -1 -1
   1  1 -1 -1 -1  1 -1  1  1  1 -1]
 [ 1  1  1  1 -1  1 -1 -1 -1 -1  1  1 -1 -1 -1 -1  1  1  1  1 -1  1 -1  1 -1
  -1  1 -1 -1 -1  1 -1  1 -1 -1 -1  1]
 [ 1 -1 -1 -1 -1  1  1 -1 -1 -1 -1  1  1 -1 -1 -1 -1  1  1 -1 -1 -1 -1  1  1 -1 -1 -1 -1
   1  1 -1 -1 -1 -1 -1  1  1  1 -1]
 [ 1 -1 -1 -1 -1  1  1 -1 -1 -1 -1  1 -1  1 -1 -1 -1 -1  1 -1 -1 -1 -1  1 -1  1
  -1  1 -1 -1 -1 -1  1  1 -1 -1 -1 -1  1]]



[[ 1 -1 -1 -1 -1 -1 -1 -1 -1 -1]
 [-1  1 -1 -1 -1 -1 -1 -1 -1 -1]
 [-1 -1  1 -1 -1 -1 -1 -1 -1 -1]
 [-1 -1 -1  1 -1 -1 -1 -1 -1 -1]
 [-1 -1 -1 -1  1 -1 -1 -1 -1 -1]
 [-1 -1 -1 -1 -1  1 -1 -1 -1 -1]
 [-1 -1 -1 -1 -1 -1  1 -1 -1 -1]
 [-1 -1 -1 -1 -1 -1 -1  1 -1 -1]
 [-1 -1 -1 -1 -1 -1 -1 -1  1 -1]
 [-1 -1 -1 -1 -1 -1 -1 -1 -1  1]]
```

Wyświetlam wylosowane dla mnie litery.

```
net.show(X)
```

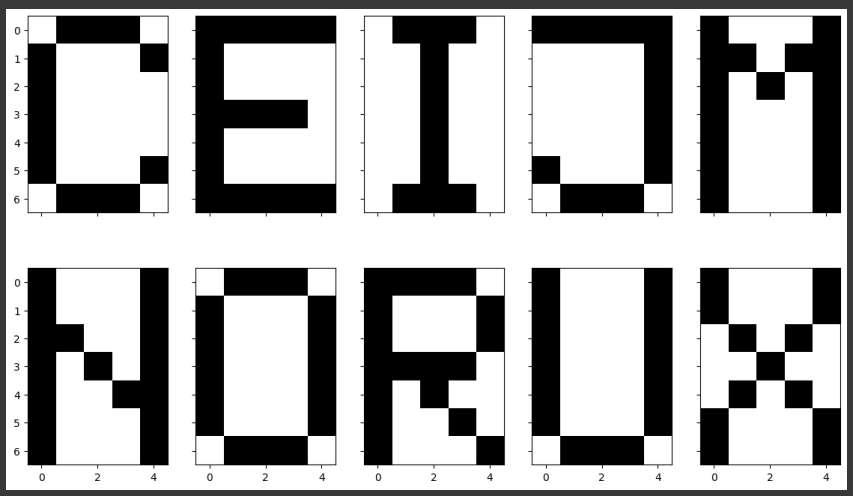

Uczenie modelu

Cały proces uczenia odbywa się w komórce poniżej.

```
net.fit(X, y)
```

```
/usr/local/lib/python3.10/dist-packages/sklearn/linear_model/_stochastic_gradient.py:702: ConvergenceWarning: Maximum number of ite
  warnings.warn(
```

Wywołuje metodę `net.predict(X)` , aby uzyskać od modelu odpowiedzi.

```
print(net.predict(X))
```

```
[[ 1. -1. -1. -1. -1. -1. -1. -1. -1. -1.]
 [-1.  1. -1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1.  1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1.  1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1.  1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1.  1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1.  1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1.  1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1. -1.  1. -1.]
 [-1. -1. -1. -1. -1. -1. -1. -1. -1.  1.]]
```

```
       [-1. -1. -1. -1. -1. -1. -1. -1.  1. -1.]
       [-1. -1. -1. -1. -1. -1. -1. -1. -1.  1.]]
```

Sprawdzam, czy model popełnił jakieś błędy.

```
print(net.misclassified(X, y))
```

```
     0
```

Testowanie możliwości modelu

Definiuje funckję `damage(X, percent, seed=1)`.

```
def damage(X, percent, seed=1):
  rgen = np.random.RandomState(seed)
  result = np.array(X)
  count = int(X.shape[1]*percent/100)

  for indeks_example in range(len(X)):
    order = np.sort(rgen.choice(X.shape[1], count, replace=False))
    for indeks_pixel in order:
      result[indeks_example][indeks_pixel] *= -1

  return result
```

Następnie tworze 3 dodatkowe zbiory, uszkodzone o kolejno:

- 5%
- 15%
- 40%

```
damaged5 = damage(X, 5)
damaged15 = damage(X, 15)
damaged40 = damage(X, 40)
```

Wyświetlam graficznie pierwszy zbiór.

```
net.show(damaged5)
```

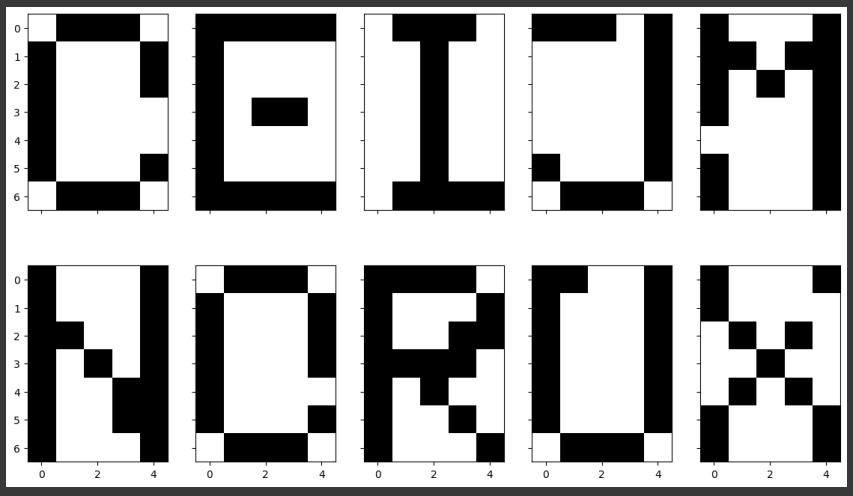

Wywołuje metodę predict przekazując uszkodzony zbiór.

```
print(net.predict(damaged5))
```

```
     [[ 1. -1. -1. -1. -1. -1.  1. -1. -1. -1.]
      [-1.  1. -1. -1. -1. -1. -1. -1. -1. -1.]
```

```
 [-1. -1.  1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1.  1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1.  1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1.  1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1.  1. -1.  1. -1.  1.]]
```

Wywołuje metode misclassified, aby sprawdzić ile błędów zostało popełnionych podczas ostatniej predykcji.

Jak widać, aż 6 razy litera została źle zinterpretowana.

```
print(net.misclassified(damaged5, y))
```

```
6
```

W następnych linijkach powtarzam powyższe kroki dla zestawów `damage15` oraz `damage40`.

```
net.show(damaged15)
```

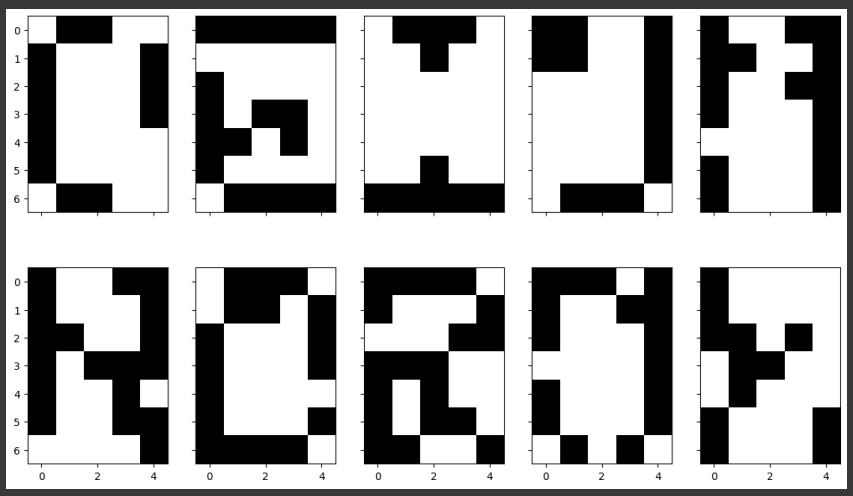

```
print(net.predict(damaged15))
```

```
[[-1. -1. -1. -1. -1. -1.  1. -1. -1. -1.]
 [-1.  1.  1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1.  1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1.  1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1.  1. -1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1.  1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1.  1. -1. -1.]
 [-1. -1. -1. -1. -1. -1. -1. -1. -1. -1.]
 [-1. -1. -1. -1. -1.  1. -1. -1. -1.  1.]]
```

Tym razem 8 błędów.

```
print(net.misclassified(damaged15, y))
```

```
8
```

```
net.show(damaged40)
```

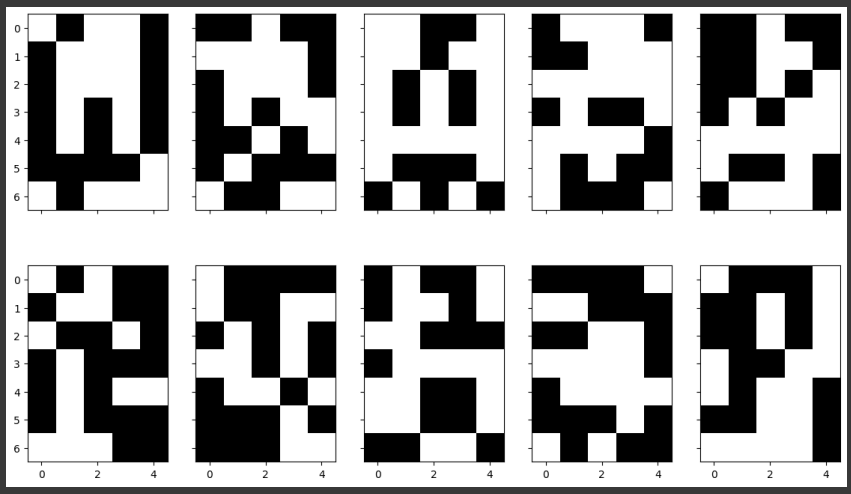

```
print(net.predict(damaged40))
```

```
[[-1. -1.  1. -1.  1. -1. -1. -1.  1.  1.]
 [-1. -1.  1.  1. -1. -1.  1. -1. -1.  1.]
 [-1. -1.  1. -1. -1. -1. -1.  1. -1. -1.]
 [-1. -1.  1. -1. -1. -1.  1. -1.  1.  1.]
 [-1. -1. -1. -1. -1. -1. -1. -1. -1.  1.]
 [-1. -1. -1. -1. -1. -1. -1. -1. -1.  1.]
 [-1. -1. -1. -1. -1. -1.  1. -1.  1.  1.]
 [-1. -1.  1. -1. -1.  1. -1.  1. -1.  1.]
 [-1. -1. -1.  1. -1. -1. -1. -1. -1. -1.]
 [-1. -1.  1. -1.  1. -1. -1. -1. -1.  1.]]
```

Aż 29 błędów (większość perceptronów reaguje pozytywnie na więcej niż jedną literę z zestawu damaged40).

```
print(net.misclassified(damaged40, y))
```

```
29
```